

Guía de Implementación: Visual RAG y Orquestación de Mundos

Esta guía detalla cómo conectar técnicamente un LLM local con tus modelos visuales para crear un sistema que “recuerde” tus datos antiguos y genere contenido nuevo basado en ellos.

1. Concepto de Visual RAG (Generación Aumentada por Recuperación Visual)

A diferencia del RAG tradicional que busca texto, el **Visual RAG** busca características visuales (estilos, objetos, planos) de tu base de datos cerrada para guiar la generación de la IA.

Flujo de Datos

1. **Base de Datos:** Tus imágenes y videos antiguos etiquetados.
 2. **Búsqueda (Retrieval):** El LLM identifica qué elementos de tu base de datos coinciden con la petición del usuario.
 3. **Generación (Generation):** Se inyectan esas referencias visuales en el modelo generativo.
-

2. Implementación Paso a Paso

Paso 1: Configuración del Cerebro (LLM Local)

Instala **Ollama** para ejecutar modelos de lenguaje en tu PC.

- **Comando:** `ollama run llama3.2`
- Este modelo será el encargado de recibir la orden del usuario y traducirla a parámetros técnicos para la imagen.

Paso 2: El Motor de Generación (ComfyUI)

Usaremos **ComfyUI** porque permite una orquestación visual mediante nodos, lo cual es mucho más fácil que programar.

1. **Instalar ComfyUI-Manager:** Para descargar extensiones automáticamente.
2. **Instalar IP-Adapter:** Este es el nodo clave. Permite que le pases una imagen de tus datos antiguos y la IA la use como “guía de estilo” sin necesidad de re-entrenar todo el modelo.

Paso 3: Entrenamiento de Expertos (LoRA)

Si tienes un estilo muy específico (ej. “Coches de los años 50 en blanco y negro”), entrena un LoRA usando **Kohya_ss**.

- **Input:** Tus 30 fotos de coches.
- **Output:** Un archivo `.safetensors` de unos 200MB.
- **Uso:** El LLM activará este archivo solo cuando el usuario mencione “coche antiguo”.

3. Guía de Ejecución y Orquestación

Para que el sistema funcione solo, configura un flujo en ComfyUI con esta lógica:

Nodo	Función	Configuración
LLM Prompt Node	Recibe la idea del usuario.	Conectado a Ollama (Llama 3).
Router Logic	Decide qué LoRA cargar.	Si el texto contiene “coche”, carga <code>coche_50s.safetensors</code> .
IP-Adapter	Inyecta una imagen de referencia.	Selecciona una imagen aleatoria de tu carpeta de “datos antiguos”.
Video/Image Gen	Genera el resultado final.	Usa Flux.1 o LTX-Video como base.

4. Refuerzo y Mejora (Reinforcement Learning)

Para que el modelo “aprenda” qué planos o combinaciones te gustan más:

1. **Carpeta de Éxitos:** Crea una carpeta llamada `outputs_favoritos`.
2. **Re-entrenamiento Mensual:** Cada vez que tengas 20 imágenes nuevas en esa carpeta, vuelve a ejecutar el entrenamiento en Kohya_ss añadiendo estas imágenes.
3. **Ajuste de Prompts:** Si el LLM se equivoca, ajusta su “System Prompt” diciéndole:
“Recuerda que para coches antiguos, siempre debes usar el LoRA de los años 50”.

5. Enlaces y Recursos de Descarga

- **Software Base:**
 - [Ollama \(LLM Local\)](#)
 - [ComfyUI \(Orquestador\)](#)
- **Modelos Libres:**
 - [Flux.1 Schnell \(Imágenes rápidas\)](#)
 - [LTX-Video \(Videos de mundo\)](#)
- **Cursos y Videos:**
 - [Curso de ComfyUI para Principiantes](#)
 - [Tutorial de Entrenamiento LoRA](#)